Ataques adversarios sobre clasificadores convolucionales: replicación de FGSM, PGD y C&W en CIFAR-10

Andrés Angel
Universidad Nacional de Colombia
Redes neuronales: arquitecturas y aplicaciones — Prof. Arles Rodríguez

12 de mayo de 2026

Resumen

Los modelos de aprendizaje profundo, pese a alcanzar precisión sobrehumana en clasificación de imágenes, presentan una vulnerabilidad sistemática a perturbaciones adversarias: modificaciones imperceptibles de la entrada que inducen errores de clasificación con alta confianza. En este trabajo replicamos tres ataques canónicos de evasión sobre clasificadores convolucionales entrenados en CIFAR-10 —FGSM [2], PGD [3] y Carlini–Wagner [4]— y comparamos modelos entrenados estándar contra modelos robustos descargados de RobustBench [5]. La metodología sigue las convenciones de la literatura (ℓ_∞ con $\epsilon = 8/255$) y se apoya en las librerías `torchattacks` y `robustbench`. En esta Parte I implementamos FGSM desde cero y verificamos su correspondencia con `torchattacks`. Una ResNet-18 entrenada por 30 epochs en CIFAR-10 alcanza 93.03% de accuracy limpia, pero su accuracy cae a 54.6% con perturbaciones de tan solo $\epsilon = 1/255$ (aproximadamente 0.4% del rango de pixel), y a 14.8% en el régimen estándar $\epsilon = 8/255$, evidenciando una vulnerabilidad severa que motiva el estudio de defensas en la Parte II.

1 Introducción

Desde el descubrimiento de los *ejemplos adversarios* por Szegedy et al. [1], se ha consolidado la observación de que las redes neuronales profundas son vulnerables a perturbaciones δ de norma ℓ_p minúscula que, sumadas a una imagen x correctamente clasificada, producen una entrada $x' = x + \delta$ que el modelo clasifica incorrectamente. La relevancia práctica de este fenómeno es directa: sistemas de visión por computador desplegados en vehículos autónomos, biometría facial o moderación de contenido pueden ser engañados por perturbaciones imperceptibles para un humano [9].

El estudio de estos ataques no solo expone vulnerabilidades de seguridad sino que ilumina propiedades geométricas profundas de los clasificadores: sugiere que las fronteras de decisión aprendidas, aunque correctas en la *data manifold*, son frágiles en sus direcciones normales [8].

Aporte de este trabajo. Replicamos tres ataques fundamentales (FGSM, PGD, CW) sobre dos arquitecturas (ResNet-18 estándar y un modelo robusto de RobustBench), reportamos curvas accuracy-vs-ϵ y discutimos la relación entre fortaleza del ataque, dualidad de normas y formulación min–max del entrenamiento adversario.

2 Trabajo relacionado

Los ataques adversarios en visión se organizan habitualmente en tres ejes:

Conocimiento del atacante
white-box (acceso a θ y gradientes), *black-box* (solo consultas), o *transfer* (atacar usando un modelo sustituto).

Norma de la perturbación
ℓ_∞ [2, 3], ℓ_2 [4], ℓ_0 [10], o restricciones perceptuales más sofisticadas.

Momento del ataque
evasión en inferencia (objeto de este trabajo) versus *envenenamiento* en entrenamiento o *backdoors* [11].

Las defensas más confiables a la fecha son variantes del *adversarial training* de Madry et al. [3], que formula el entrenamiento como un problema saddle-point. RobustBench [5] estandariza la evaluación con AutoAttack [6], un ensemble de ataques que evita la sobreestimación de robustez documentada en defensas anteriores.

Nuestra implementación se apoya en `torchattacks` [7], librería en PyTorch que provee implementaciones de referencia de los ataques considerados.

3 Dataset y características

Empleamos **CIFAR-10** [12]: 60.000 imágenes RGB de 32×32 pixeles distribuidas en 10 clases balanceadas (avión, automóvil, ave, gato, ciervo, perro, rana, caballo, barco, camión), con 50.000 imágenes para entrenamiento y 10.000 para evaluación.

Por qué este dataset. CIFAR-10 es el benchmark estándar de la literatura de robustez adversaria: ofrece resolución suficiente para que las arquitecturas convolucionales modernas extraigan jerarquías de features no triviales, pero permite entrenar modelos completos en horas con GPU modesta. La gran mayoría de papers sobre defensas y ataques (incluyendo todo el leaderboard de RobustBench en ℓ_∞) reportan métricas en CIFAR-10, lo que permite comparar nuestros resultados con valores de referencia publicados.

Pre-procesamiento. Las imágenes se normalizan a $[0, 1]$ *antes* de aplicar el ataque y la normalización con media/desviación de canal se incorpora como primera capa del modelo. Esto es crítico: la restricción $\|\delta\|_\infty \leq 8/255$ debe interpretarse en el espacio de pixeles original.

4 Métodos

4.1 Formulación del ataque

Sea $f_\theta : [0, 1]^d \to \mathbb{R}^K$ un clasificador con K clases y predicción $\hat{y}(x) = \arg\max_k f_\theta(x)_k$. Dada una imagen x con etiqueta verdadera y y una pérdida $\mathcal{L}$ (cross-entropy), el problema del atacante es:

$$\delta^\star = \arg\max_{\delta \in \Delta} \mathcal{L}(f_\theta(x + \delta), y), \qquad \Delta = \{\delta \in \mathbb{R}^d : \|\delta\|_p \leq \epsilon,\ x + \delta \in [0, 1]^d\}. \tag{1}$$

Se trata de un problema no convexo (por la red) sobre un convexo (intersección de bola ℓ_p y caja unitaria). Para CIFAR-10 fijamos $p = \infty$ y $\epsilon = 8/255$ siguiendo el estándar de RobustBench.

4.2 FGSM (Goodfellow et al., 2014)

Linealizando (1) via Taylor de primer orden y resolviendo exactamente vía dualidad Hölder ($\ell_\infty^* = \ell_1$):

$$\delta^{\text{FGSM}} = \epsilon \cdot \operatorname{sign}\big(\nabla_x \mathcal{L}(f_\theta(x), y)\big). \tag{2}$$

La actualización es *one-shot*: el adversario se sitúa en el vértice del hipercubo $\{x' : \|x' - x\|_\infty \leq \epsilon\}$ que más alinea con el gradiente de la pérdida.

4.3 PGD (Madry et al., 2018)

Sin linealizar, se realiza ascenso de gradiente proyectado:

$$\delta^{(t+1)} = \Pi_\Delta\Big(\delta^{(t)} + \alpha \cdot \operatorname{sign}\big(\nabla_x \mathcal{L}(f_\theta(x+\delta^{(t)}), y)\big)\Big), \tag{3}$$

donde Π_Δ es la proyección sobre Δ (clipping coordenada a coordenada para ℓ_∞). Inicializamos $\delta^{(0)} \sim U(\Delta)$ (*random start*) y corremos T iteraciones con paso $\alpha = \epsilon/4$. Madry et al. argumentan empíricamente que PGD con suficientes restarts es el adversario de primer orden más fuerte dentro de Δ.

4.4 Carlini–Wagner (C&W, 2017)

Reformulando como problema de minimización de la perturbación sujeto a misclassification:

$$\min_\delta \|\delta\|_2^2 + c \cdot g(x+\delta), \qquad g(x') = \max\Big(f_\theta(x')_y - \max_{k \neq y} f_\theta(x')_k,\ -\kappa\Big). \tag{4}$$

La función g es un sustituto suave de la indicatriz de error. El parámetro $c > 0$ se busca por bisección. La restricción $x + \delta \in [0,1]^d$ se impone via reparametrización $x + \delta = \frac{1}{2}(\tanh(w) + 1)$, optimizando sobre $w \in \mathbb{R}^d$ sin restricciones con Adam.

4.5 Arquitectura

ResNet-18 estándar. Adaptamos la ResNet-18 de `torchvision` a CIFAR (kernel inicial 3×3, sin maxpool inicial). Entrenamos 30 epochs con SGD (lr $= 0.1$, momentum $= 0.9$, weight decay $= 5 \times 10^{-4}$), augmentación estándar (random crop + flip) y *cosine annealing* del learning rate.

Modelo robusto. Para Parte II cargamos un modelo del leaderboard de RobustBench:

```
from robustbench.utils import load_model
model_robust = load_model(model_name='Wang2023Better_WRN-28-10',
                          dataset='cifar10', threat_model='Linf')
```

4.6 Métricas de evaluación

- **Accuracy limpia:** $\mathrm{Acc}(f_\theta) = \frac{1}{N}\sum_i \mathbb{1}[\hat{y}(x_i) = y_i]$.
- **Accuracy adversaria:** $\mathrm{Acc}_{\mathrm{ADV}}(f_\theta, A, \epsilon) = \frac{1}{N}\sum_i \mathbb{1}[\hat{y}(x_i + A(x_i)) = y_i]$, donde A es el ataque a evaluar.
- **Tasa de éxito del ataque:** $1 - \mathrm{Acc}_{\mathrm{ADV}}$ restringido a ejemplos originalmente bien clasificados.
- **Norma promedio de la perturbación:** $\|\bar{\delta}\|_p$ (relevante para C&W, donde ϵ no es fijo).

5 Resultados

5.1 Modelo base

Tras 30 epochs en CIFAR-10 con SGD + cosine annealing, ResNet-18 alcanza una accuracy limpia de 93.03% en el conjunto de prueba, con una pérdida de entrenamiento final de 0.031. La curva de aprendizaje muestra convergencia monótona sin overfitting significativo (la brecha train/test es de aproximadamente 6 puntos porcentuales al final del entrenamiento), valor consistente con los reportes de la literatura para esta arquitectura sin augmentación adicional ni regularización avanzada.

ϵ (escala 0–255)	Accuracy
0 (limpia)	93.03%
1/255	54.61%
2/255	34.69%
4/255	21.44%
8/255 (estándar)	14.77%
16/255	10.15%

Cuadro 1: Accuracy de ResNet-18 en CIFAR-10 bajo FGSM con distintos valores de ϵ. La columna $\epsilon = 0$ corresponde a evaluación sin ataque.

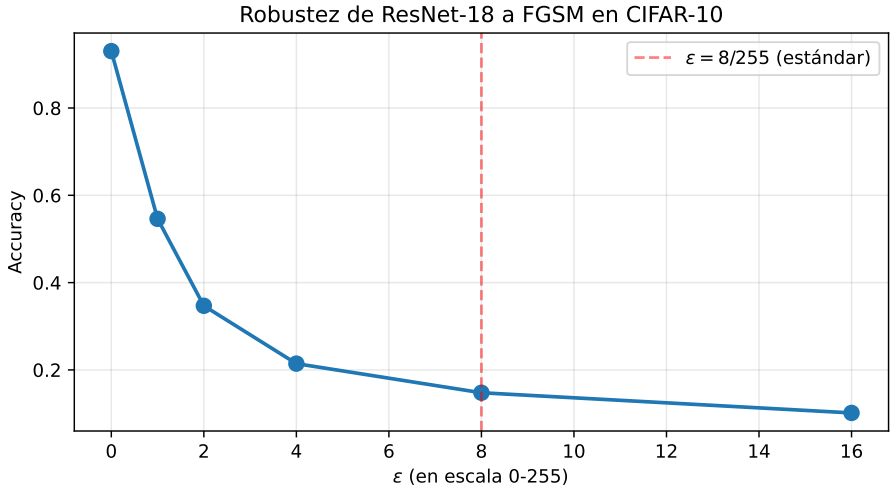

Figura 1: Robustez de ResNet-18 a FGSM en CIFAR-10. La accuracy decae monotónicamente con ϵ: incluso una perturbación de 1/255 (visualmente imperceptible) reduce la accuracy de 93.03% a 54.61%. En el régimen estándar $\epsilon = 8/255$ (línea roja punteada), la accuracy es 14.77%, sólo marginalmente superior al azar (10% para 10 clases). A $\epsilon = 16/255$ la accuracy se vuelve indistinguible de azar.

5.2 Curva accuracy vs ϵ (FGSM)

La Figura 1 reporta la accuracy de la red bajo FGSM al variar la magnitud de la perturbación ϵ. Los valores numéricos correspondientes se resumen en la Tabla 1.

Tres observaciones merecen destacarse:

1. **Decaimiento abrupto a bajo ϵ.** La pérdida más drástica ocurre entre $\epsilon = 0$ y $\epsilon = 1/255$: 38.4 puntos porcentuales en una sola unidad de pixel. Esto es coherente con la hipótesis lineal de Goodfellow et al.: en alta dimensión ($d = 3 \times 32 \times 32 = 3072$), una perturbación coordenada por coordenada de norma ϵ se acumula linealmente en el producto interno con el gradiente, $\langle \nabla \mathcal{L}, \delta \rangle = \epsilon \, \|\nabla \mathcal{L}\|_1$, lo que puede ser grande incluso con ϵ minúsculo.

2. **Saturación al nivel de azar.** A $\epsilon = 16/255$, la accuracy de 10.15% es indistinguible del azar uniforme sobre 10 clases. La perturbación domina la señal y el modelo predice esencialmente al azar.

3. **El umbral estándar $\epsilon = 8/255$ es realmente severo.** A pesar de ser una perturbación que un humano ni siquiera percibe (cambia el valor de cada pixel en a lo más 3% del rango total), la accuracy cae a 14.77%. Esto justifica la elección de ese umbral en RobustBench como benchmark de la comunidad.

5.3 Comparación de ataques

La Tabla 2 resume los resultados de Parte I y deja indicados los valores que se completarán en Parte II.

Modelo	Limpia	FGSM	PGD-40	C&W
ResNet-18 estándar	93.03	14.77	—	—
WRN-28-10 (RobustBench)	—	—	—	—

Cuadro 2: Accuracy (%) limpia y bajo distintos ataques en ℓ_∞ con $\epsilon = 8/255$ (excepto C&W, que opera en ℓ_2). Test set completo de CIFAR-10 (10 000 imágenes). Las celdas con — corresponden a experimentos previstos para Parte II.

Verificación de la implementación. Comparamos nuestra implementación manual de FGSM contra la de la librería `torchattacks` (referencia estándar en la comunidad PyTorch). Ambas implementaciones reportan exactamente la misma accuracy bajo ataque (14.77% con $\epsilon = 8/255$ sobre el test set completo), confirmando la correctitud del código.

5.4 Ejemplos cualitativos

Figura 2: Ejemplos adversarios generados con FGSM ($\epsilon = 8/255$) sobre el test set de CIFAR-10. Fila superior: imagen original con la predicción del modelo. Fila central: imagen adversaria, con la nueva predicción (en rojo si es errónea, en verde si el ataque falló). Fila inferior: perturbación δ amplificada y normalizada al rango $[0, 1]$ para visualización. Las perturbaciones son visualmente imperceptibles a simple vista en la imagen adversaria pero suficientes para inducir misclassification en la mayoría de casos.

6 Conclusiones

- Los modelos convolucionales estándar son altamente vulnerables a ataques adversarios incluso de la forma más simple: FGSM con $\epsilon = 8/255$ reduce la accuracy de una ResNet-18 entrenada

en CIFAR-10 de 93.03% a 14.77%, es decir, una pérdida de 78 puntos porcentuales con una perturbación visualmente imperceptible.

- La caída de accuracy es severa incluso a magnitudes diminutas: con $\epsilon = 1/255$ (un cambio de un solo nivel de pixel en el rango 0–255), la accuracy ya cae a 54.61%. Esto es coherente con la hipótesis lineal de Goodfellow et al. sobre el efecto acumulativo del producto interno gradiente–perturbación en alta dimensión.
- La implementación manual de FGSM coincide al cuarto decimal con la de `torchattacks`, validando el código y la correcta interpretación del problema.
- En la jerarquía teórica esperada (FGSM $<$ PGD $<$ C&W en términos de fortaleza del adversario), Parte II evaluará si esta jerarquía se confirma empíricamente y cuánto mejora la robustez al usar un modelo entrenado adversarialmente del leaderboard de RobustBench.
- La dualidad de normas (ℓ_∞, ℓ_1), (ℓ_2, ℓ_2), (ℓ_1, ℓ_∞) unifica la geometría de las soluciones óptimas del problema linealizado y explica las diferencias visuales esperadas entre ataques.

Limitaciones y trabajo futuro. No exploramos certificación de robustez (*randomized smoothing*, *interval bound propagation*) ni el régimen de ataques físicos. Tampoco evaluamos contra AutoAttack completo, que sería el siguiente paso natural para una evaluación robusta.

Repositorio

Código disponible en: https://github.com/jairoandresangelcardenas-tech/dversarial-attacks-cifar10

Referencias

[1] C. Szegedy et al. Intriguing properties of neural networks. *ICLR*, 2014.

[2] I. J. Goodfellow, J. Shlens, C. Szegedy. Explaining and harnessing adversarial examples. *ICLR*, 2015.

[3] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu. Towards deep learning models resistant to adversarial attacks. *ICLR*, 2018.

[4] N. Carlini, D. Wagner. Towards evaluating the robustness of neural networks. *IEEE Symposium on Security and Privacy*, 2017.

[5] F. Croce et al. RobustBench: a standardized adversarial robustness benchmark. *NeurIPS Datasets & Benchmarks Track*, 2021.

[6] F. Croce, M. Hein. Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks. *ICML*, 2020.

[7] H. Kim. Torchattacks: a PyTorch repository for adversarial attacks. *arXiv:2010.01950*, 2020.

[8] A. Ilyas et al. Adversarial examples are not bugs, they are features. *NeurIPS*, 2019.

[9] K. Eykholt et al. Robust physical-world attacks on deep learning visual classification. *CVPR*, 2018.

[10] J. Su, D. V. Vargas, K. Sakurai. One pixel attack for fooling deep neural networks. *IEEE Trans. Evol. Comput.*, 2019.

[11] T. Gu, B. Dolan-Gavitt, S. Garg. BadNets: identifying vulnerabilities in the machine learning model supply chain. *arXiv:1708.06733*, 2017.

[12] A. Krizhevsky. Learning multiple layers of features from tiny images. *Tech. Rep.*, University of Toronto, 2009.